
Deteksi Proaktif Pinjaman Online Ilegal dan Scam Finansial menggunakan Klasifikasi Multimodal dan Agen Otonom Berbasis Large Language Model

Danar Iqbal Abi
Universitas Indonesia
danariqbal0210@gmail.com

Muhammad Akmal Haqqani
Universitas Indonesia
haqqaniakmal@gmail.com

Nugraha Kautsarrizqi Caksana
Universitas Indonesia
nugrahakc@gmail.com

Abstract

Pinjaman online (pinjol) ilegal dan scam finansial menyebabkan kerugian masyarakat Indonesia yang terus meningkat, sementara seluruh solusi deteksi yang tersedia saat ini bersifat reaktif dan baru bertindak setelah laporan korban masuk. Makalah ini mengusulkan SIGAP (Sistem Intelijen multimodal dan agen otonom untuk deteksi proaktif pinjol ilegal), rancangan sistem deteksi *proaktif* yang menggabungkan klasifikasi multimodal, meliputi pemrosesan bahasa alami (*NLP*) untuk analisis teks, visi komputer (*CV*) untuk forensik bukti tangkapan layar, dan analisis graf untuk resolusi jaringan entitas. Hasil deteksi ditindaklanjuti oleh agen otonom yang menjalankan siklus tertutup verifikasi multi-sumber, penentuan prioritas, penyusunan laporan, dan pemantauan lanjutan, dengan kemampuan penalaran yang ditenagai *Large Language Model* (LLM). Sistem yang diusulkan dirancang untuk mendeteksi indikasi entitas ilegal dari jejak digital publik sebelum korban berikutnya dirugikan, sekaligus mengenali pola pemunculan ulang entitas yang telah diblokir. Rancangan ini disertai rencana studi ablatasi agar kontribusi tiap modalitas terhadap keputusan akhir dapat diverifikasi secara empiris pada tahap pengembangan berikutnya.

1 Pendahuluan

1.1 Latar Belakang

Sektor jasa keuangan digital Indonesia menghadapi ancaman pinjaman online (pinjol) ilegal dan scam finansial yang terus meningkat. Sejak 2017 hingga Mei 2025, Satuan Tugas Pemberantasan Aktivitas Keuangan Ilegal (Satgas PASTI) telah menghentikan 13.228 entitas keuangan ilegal, 11.166 di antaranya entitas pinjol/pinjaman pribadi (pinpri) [1]. Sepanjang 2025, 2.263 entitas pinjol ilegal dan 354 penawaran investasi ilegal dihentikan dari 26.220 pengaduan yang diterima Otoritas Jasa Keuangan (OJK) [2]. Volume pengaduan belum menunjukkan perlambatan: pada semester pertama 2026, OJK menerima 22.206 pengaduan baru dan Satgas PASTI menghentikan 951 entitas pinjol ilegal, sementara secara kumulatif hingga akhir Juni 2026 sebanyak 557.751 rekening terkait penipuan telah diblokir [3]. Skala kerugian finansial jauh lebih mengkhawatirkan daripada jumlah entitas yang ditindak. Indonesia Anti-Scam Centre (IASC) mencatat kerugian korban scam finansial mencapai Rp7,8 triliun sejak mulai beroperasi pada 22 November 2024 hingga 11 November 2025, sementara dana yang berhasil diblokir hanya sekitar Rp386,5 miliar, kurang dari 5% dari total kerugian yang dilaporkan [4]. Hingga akhir Juni 2026, dana yang berhasil diblokir tercatat

Rp674,1 miliar, dengan Rp196,93 miliar di antaranya telah dikembalikan kepada korban [3]. Gambar 1 merangkum kedua besaran tersebut. Kesenjangan besar antara kerugian dan pemulihan ini menunjukkan bahwa mekanisme penanganan saat ini bersifat *reaktif*, baru bertindak setelah laporan korban masuk, sehingga sebagian besar dana korban sudah terlanjur berpindah tangan sebelum penindakan dilakukan.

1.2 Rumusan Masalah

Solusi deteksi pinjol ilegal dan scam finansial yang tersedia saat ini seluruhnya bersifat reaktif. Satgas PASTI, platform crowdsourced seperti Kredibel [5], dan layanan resmi CekRekening.id dari Kementerian Komunikasi dan Digital [6] semuanya bergantung pada laporan masyarakat sebagai titik masuk penanganan, bukan deteksi dini sebelum korban dirugikan. Di sisi akademik, pendekatan klasifikasi teks berbasis *machine learning* seperti yang dikembangkan Arifman dkk. [7] menggunakan taksonomi ancaman siber lokal dengan model hibrida IndoBERT dan mencapai akurasi 96,8%, namun cakupannya berhenti pada klasifikasi wacana tekstual. Pendekatan tersebut belum memiliki kemampuan resolusi jaringan untuk mendeteksi entitas ilegal yang muncul kembali dengan identitas baru setelah diblokir, dan belum memiliki mekanisme tindak lanjut otomatis. Kesenjangan tersebut menunjukkan kebutuhan akan sistem deteksi proaktif yang mengidentifikasi indikasi aktivitas ilegal dari jejak digital publik sebelum kerugian meluas. Sistem itu perlu multimodal, mengingat bukti pinjol ilegal umumnya berbentuk kombinasi teks keluhan, tangkapan layar, dan pola penggunaan ulang identitas. Sistem juga perlu *agentic*, menindaklanjuti hasil deteksi secara otonom hingga pelaporan dan pemantauan, tidak berhenti pada klasifikasi.


1.3 Tujuan dan Kontribusi

Makalah ini mengusulkan SIGAP, rancangan sistem deteksi proaktif pinjol ilegal dan scam finansial yang menggabungkan klasifikasi multimodal (NLP, CV, dan analisis graf entitas) dengan agen otonom berbasis LLM yang menjalankan siklus tertutup: verifikasi multi-sumber, penentuan skor prioritas, penyusunan laporan, hingga pemantauan lanjutan dengan *human-in-the-loop* pada titik keputusan akhir. Kontribusi utama makalah ini ada dua. Pertama, integrasi tiga modalitas sekaligus, yaitu analisis teks hibrida, forensik visual pada bukti tangkapan layar, dan resolusi graf jaringan entitas, yang dirancang saling melengkapi kelemahan tiap modalitas tunggal. Kedua, siklus *agentic* penuh dari deteksi hingga tindak lanjut yang belum ditemukan pada pendekatan reaktif yang ada saat ini. Keduanya diarahkan pada pengurangan jeda waktu antara kemunculan entitas ilegal dan penindakannya, sehingga berpotensi menutup kesenjangan pemulihan dana korban yang tercatat di bawah 5% pada November 2024–November 2025 [4].


2 Studi Literatur

2.1 Penanganan Pinjol Ilegal dan Scam Finansial secara Reaktif

Penanganan pinjol ilegal di Indonesia berjalan melalui tiga jalur yang seluruhnya reaktif: Satgas PASTI menindaklanjuti pengaduan masyarakat melalui investigasi sebelum entitas dihentikan



(a) Rata-rata pengaduan OJK per bulan [2,3].



(b) Kerugian vs. dana diblokir IASC [4].

Figure 1: Skala persoalan: (a) laju pengaduan OJK, dan (b) kerugian scam finansial vs. dana yang diblokir IASC (November 2024–November 2025).

dan IASC memblokir rekening setelah laporan diterima [1]; Kredibel menyediakan basis data *crowdsourced* untuk pengecekan rekam jejak nomor telepon atau rekening yang dicurigai [5]; dan CekRekening.id menjalankan fungsi serupa melalui basis data terpusat [6]. Ketiganya efektif sebagai mekanisme pelaporan pasca-kejadian, namun baru bekerja setelah korban menyadari kerugian dan melapor; jeda inilah salah satu penyebab rendahnya pemulihan dana, karena dana yang ditransfer umumnya sudah dipindahkan sebelum pemblokiran dimulai.

2.2 Klasifikasi Teks Berbasis NLP untuk Deteksi Ancaman Siber Berbahasa Indonesia

Penelitian deteksi ancaman siber berbahasa Indonesia banyak bertumpu pada IndoBERT, model representasi teks Bahasa Indonesia dari Koto dkk. [8] yang terbukti efektif pada berbagai tugas klasifikasi, termasuk deteksi hoaks [9]. Arifman dkk. [7] mengembangkan pendekatan klasifikasi hibrida yang menggabungkan aturan berbasis *regex* dengan IndoBERT yang di-*fine-tune* pada taksonomi ancaman siber lokal, dan mencapai akurasi 96,8% dalam mengklasifikasikan wacana kejahatan siber berbahasa Indonesia. Pendekatan hibrida ini menjadi fondasi metodologis lapis analisis teks pada sistem yang diusulkan, karena kombinasi aturan eksplisit dan model terlatih terbukti menangani variasi bahasa informal dan istilah spesifik domain pinjol. Pada domain lebih sempit, Raffles dkk. [10] mengusulkan kerangka deteksi penipuan pinjaman online berbasis *machine ethics*. Keduanya berfokus pada satu modalitas, yaitu teks, dan belum mengeksplorasi integrasi dengan sinyal visual maupun pola relasional entitas.

2.3 Posisi dan Kebaruan Penelitian

Tinjauan di atas menunjukkan tiga celah yang menjadi dasar rancangan ini: (i) seluruh solusi operasional bersifat reaktif; (ii) klasifikasi teks yang ada berhenti pada identifikasi wacana tanpa resolusi jaringan entitas; dan (iii) belum ada yang menggabungkan klasifikasi multimodal dengan siklus tindak lanjut otomatis; rancangan ini mengisi ketiganya sekaligus.

2.4 Perbandingan dengan Pendekatan Multimodal Terdahulu

Tabel 1 membandingkan rancangan ini dengan tiga sistem representatif: klasifikasi teks hibrida wacana siber Indonesia (Arifman dkk. [7]) serta dua sistem deteksi situs *phishing*, yaitu kemiripan visual murni (VisualPhishNet [11]) dan agen multimodal berbasis MLLM (PhishAgent [19]). Tidak satu pun dari ketiganya menggabungkan sinyal relasional entitas untuk mendeteksi kemuncu-

Table 1: Perbandingan dengan sistem deteksi representatif

Karakteristik	Arifman dkk. [7]	VisualPhish-Net [11]	PhishAgent [19]	SIGAP
Modalitas	1 (teks)	1 (visual)	2 (HTML+ logo)	3 (teks + visual + graf)
Fusi diuji (ablasi)	N/A	N/A	Ya	Direncanakan
Resolusi jaringan entitas	Tidak	Tidak	Tidak	Ya
Siklus lapor–pantau otonom	Tidak	Tidak	Tidak	Ya

lan ulang, dan seluruhnya berhenti pada keputusan klasifikasi. PhishAgent [19] paling dekat secara arsitektural, agen multimodal dengan ablasi per komponen, namun perannya berakhir pada label *phishing*/bukan atas satu halaman web; SIGAP memperluas peran agen hingga verifikasi silang, pelaporan ke otoritas, dan pemantauan reinkarnasi entitas pada domain pinjol ilegal Indonesia.

3 Metodologi

3.1 Arsitektur Sistem dan Siklus Agen Otonom

SIGAP disusun sebagai enam lapis berurutan: lima lapis pertama menghasilkan sinyal, sedangkan lapis keenam, agen berbasis LLM, mengubah sinyal itu menjadi tindakan. Gambar 2 menunjukkan

keduanya, dengan panel (b) memperbesar isi kotak Agen pada panel (a); Tabel 2 merangkum fungsi tiap lapis.




Figure 2: Arsitektur SIGAP: (a) alur data enam lapis, dan (b) siklus ReAct [15] di dalam lapis Agen. Umpan balik moderator dan pemantauan lanjutan mengembalikan hasil ke siklus, menjadikan alur ini *closed-loop*.

Table 2: Rancangan arsitektur enam lapis

Lapis	Fungsi
1. Akuisisi	Pemindaian berkelanjutan X/Twitter, YouTube, dan ulasan aplikasi pinjaman di <i>app store</i> , mengikuti pendekatan OSINT sejenis [7].
2. Analisis NLP	Klasifikasi teks hibrida (<i>regex</i> + IndoBERT yang di- <i>fine-tune</i> [7,8]), digabungkan melalui fusi berbasis ambang keyakinan.
3. Computer Vision	OCR pada tangkapan layar bukti, dilengkapi analisis kemiripan templat antarmuka untuk deteksi <i>UI re-use</i> dan watermark manipulatif [11,12].
4. Resolusi Jaringan	Graf entitas dari rekening/telepon/nama aplikasi yang berulang lintas laporan, untuk deteksi pola “reinkarnasi” [13,14].
5. Yurisdiksi	Pencocokan otomatis terhadap daftar resmi fintech <i>lending</i> berizin OJK.
6. Agen (LLM)	Verifikasi silang, skor prioritas, draf laporan, publikasi setelah moderasi manusia, dan pemantauan lanjutan [15].

Tiga lapis analisis (2–4) berjalan paralel atas berkas yang sama dan menghasilkan sinyal yang saling melengkapi: teks keluhan menangkap modus operandi, tangkapan layar menangkap identitas visual aplikasi, dan graf entitas menangkap keterkaitan lintas laporan. Ketiganya digabungkan melalui fusi ambang keyakinan sebelum diverifikasi terhadap daftar izin OJK, sehingga tidak ada modalitas tunggal yang dapat menetapkan status ilegal sendiri. Sinyal Resolusi Jaringan khususnya bersifat penguat keyakinan, bukan penentu, karena pelaku adaptif cenderung mengganti kontak identifikasi secara berkala. Skor gabungan itu menjadi masukan lapis keenam, tempat pembeda arsitektural utama rancangan ini terletak: alih-alih berhenti pada keluaran klasifikasi, agen menjalankan siklus *Thought–Action–Observation* mengikuti paradigma ReAct [15], sebagaimana diperbesar pada Gambar 2b. Fase *Thought* menilai kekuatan dan konsistensi sinyal ketiga modalitas serta menyusun rencana verifikasi; fase *Action* mengeksekusinya melalui verifikasi silang antar-sumber, pengecekan ulang status izin, dan penetapan skor prioritas berdasarkan keyakinan serta estimasi potensi kerugian; fase *Observation* mengumpulkan hasilnya sebagai bukti baru yang, bila keyakinan belum cukup, dikembalikan ke *Thought*. Struktur iteratif inilah pembeda agen dari fusi sederhana: agen dapat mencari bukti tambahan bila yang ada belum memadai, bukan sekadar menjumlahkan skor. Siklus berhenti ketika keyakinan melampaui ambang, dan agen menyusun laporan untuk Satgas PASTI atau IASC. Entitas berprioritas tinggi namun berkeyakinan rendah diteruskan ke peninjau manusia sebagai titik *human-in-the-loop*; keputusan moderator kembali masuk sebagai *Observation*.

tion. Agen juga memantau kemunculan ulang entitas beridentitas baru, yang bila terdeteksi memicu siklus baru. Kedua jalur umpan balik inilah yang menjadikan arsitektur ini *closed-loop*.

3.2 Spesifikasi Teknis per Lapis

Konfigurasi teknis tiap lapis berlandaskan praktik pada literatur sejenis. Pada lapis akuisisi, target volume mengacu skala Arifman dkk. [7], yaitu 2.344 sampel dari X dan YouTube dalam tiga minggu, dengan kata kunci mengikuti pola *file-based labeling* studi tersebut (mis. “kena tipu”). Kelayakan koleksi otomatis skala lebih besar didukung studi Pitumpe dan Rahmati [16] yang mengumpulkan lebih dari 29.000 pesan *scam* melalui *pipeline* berbasis LLM. Lapis analisis NLP menggunakan model dasar *indolem/indobert-base-uncased* [8], *checkpoint* yang sama dengan studi Arifman dkk. [7], di-*fine-tune* dengan *class-weighted loss* dan ambang keyakinan τ yang dioptimasi per subkategori: prediksi IndoBERT dipakai bila keyakinannya melampaui τ , dan sistem beralih ke keluaran berbasis aturan yang lebih dapat diaudit bila tidak. Pada lapis *computer vision*, OCR sejenis Tesseract dilengkapi prapemrosesan citra (skala abu-abu, kontras, reduksi derau) mengikuti Sporici dkk. [17] untuk meningkatkan akurasi pada tangkapan layar berkualitas rendah, sementara analisis kemiripan templat antarmuka mengadaptasi teknik *wavelet hashing* dan SIFT yang mencapai akurasi hingga 99,95% pada kasus terbaik untuk deteksi *phishing* visual sejenis [12], serta pendekatan *triplet CNN* untuk entitas baru (*zero-day*) [11]. Lapis resolusi jaringan membangun graf entitas dengan rekening, telepon, dan nama aplikasi sebagai simpul serta kemunculan bersama sebagai sisi, berlandaskan tinjauan sistematis *graph neural network* untuk deteksi *fraud* finansial [14] dan kerangka tahan kamufase [13]. Pendekatan ini didukung temuan empiris bahwa pelaku *scam* memakai ulang templat pesan, domain, dan infrastruktur secara ekstensif lintas kampanye [16], serta bahwa asal nomor telepon berasosiasi kuat dengan kategori kampanye tertentu sehingga dapat menjadi sinyal pengelompokan [18]. Lapis yurisdiksi memperbarui daftar fintech *lending* berizin OJK secara berkala dengan penanda usia data; ketidakcocokan terhadap daftar tersebut menjadi indikator awal status ilegal, bukan penentu tunggal. Kelayakan verifikasi dan pelaporan otonom pada lapis agen ditunjukkan oleh [16], yang mengekstraksi sinyal dari lebih dari 1.900 pelaku *scam* secara terotomasi.

3.3 Rencana Evaluasi dan Studi Ablasi

Sebagai rancangan tahap proposal, metrik berikut merupakan rencana pengukuran, bukan hasil. Lapis NLP dan CV dievaluasi dengan *precision*, *recall*, dan *F1-score* per kelas, dengan akurasi acuan dari literatur (96,8% [7]; hingga 99,95% [12]) sebagai tolak ukur kelayakan dan bukan target mutlak, mengingat perbedaan domain data. Lapis Resolusi Jaringan dievaluasi melalui presisi pasangan entitas “reinkarnasi”, yaitu proporsi pasangan yang benar-benar merujuk operator sama. Sebagai metrik khas klaim proaktif, direncanakan pengukuran *lead time*: selisih waktu antara deteksi sistem dan tanggal publikasi resmi entitas pada daftar Satgas PASTI. Klaim manfaat multimodal diverifikasi melalui ablasi lima konfigurasi: (i) NLP saja, (ii) CV saja, (iii) Resolusi Jaringan saja, (iv) gabungan tiga modalitas dengan fusi sederhana tanpa Agen, dan (v) gabungan penuh via Agen. Selisih (i)–(iii) terhadap (iv) mengukur manfaat multimodalitas; selisih (v) terhadap (iv) mengisolasi kontribusi penalaran LLM, meneruskan praktik ablasi per komponen sebagaimana PhishAgent [19] (Bagian 2.4). Hipotesis awal: sinyal visual bukti pinjol ilegal (penggunaan ulang templat antarmuka) lebih diskriminatif dibanding domain visual umum karena pelaku cenderung memakai kembali aset UI lintas aplikasi [11,12]; diuji melalui kontribusi per-modalitas pada tahap ablasi.

3.4 Batasan

Empat keterbatasan perlu diakui. Pertama, lapis akuisisi bergantung pada API pihak ketiga (X/Twitter, YouTube) yang terbatas laju dan dapat berubah kebijakan; mitigasinya *scraping* ulasan toko aplikasi sebagai cadangan. Kedua, sinyal Resolusi Jaringan melemah bila pelaku mengganti identitas kontak secara adaptif. Ketiga, lapis Yurisdiksi bergantung pada dokumen OJK yang diperbarui manual, bukan API *real-time*. Keempat, seluruh angka acuan performa di atas adalah tolak ukur kelayakan dari literatur sejenis, bukan hasil terverifikasi pada data pinjol ilegal Indonesia.

References

- [1] OJK – Siaran Pers Satgas PASTI, Juni 2025.
- [2] Tempo – “OJK Blokir 2.263 Pinjol dan 354 Investasi Ilegal di 2025,” Januari 2026.
- [3] Infobanknews – “OJK Terima 22 Ribu Pengaduan dan Blokir 951 Pinjol Ilegal per Juni 2026,” Juli 2026.
- [4] OJK – Siaran Pers Satgas PASTI, November 2025.
- [5] Kredibel – kredibel.com.
- [6] CekRekening.id – Kemkomdigi.
- [7] F. Arifman, T. Mantoro, D.O.D. Handayani (2026) “A Hybrid Machine Learning Approach for Classifying Indonesian Cybercrime Discourse Using a Localized Threat Taxonomy,” *Information*, 17(3), 301.
- [8] F. Koto, A. Rahimi, J.H. Lau, T. Baldwin (2020) “IndoLEM and IndoBERT,” *COLING 2020*, pp. 757–770.
- [9] M.Y. Ridho, E. Yulianti (2024) IndoBERT untuk deteksi hoax, *JITEKI* 10(3).
- [10] N. Raffles, M. Aldeno, M.D.B. Saputra, T. Sutabri (2025) “Deteksi Penipuan Digital pada Layanan Pinjaman Online Berbasis Machine Ethics,” *BUSINESS: Scientific Journal of Business and Entrepreneurship*, 3(1), 11–19.
- [11] S. Abdelnabi, K. Krombholz, M. Fritz (2020) “VisualPhishNet: Zero-Day Phishing Website Detection by Visual Similarity,” *Proc. ACM SIGSAC Conference on Computer and Communications Security (CCS)*, 1681–1698.
- [12] J.-L. Chen, Y.-W. Ma, K.-L. Huang (2020) “Intelligent Visual Similarity-Based Phishing Websites Detection,” *Symmetry*, 12(10), 1681.
- [13] Y. Dou, Z. Liu, L. Sun, Y. Deng, H. Peng, P.S. Yu (2020) “Enhancing Graph Neural Network-based Fraud Detectors against Camouflaged Fraudsters,” *Proc. 29th ACM International Conference on Information and Knowledge Management (CIKM)*, 315–324.
- [14] S. Motie, B. Raahemi (2024) “Financial Fraud Detection Using Graph Neural Networks: A Systematic Review,” *Expert Systems with Applications*, 240, 122156.
- [15] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, Y. Cao (2023) “ReAct: Synergizing Reasoning and Acting in Language Models,” *International Conference on Learning Representations (ICLR)*.
- [16] A. Pitumpe, A. Rahmati (2026) “Anansi: Scalable Characterization of Message-Based Job Scams,” *arXiv:2602.24223*.
- [17] D. Sporici, E. Cuşnir, C.-A. Boiangiu (2020) “Improving the Accuracy of Tesseract 4.0 OCR Engine Using Convolution-Based Preprocessing,” *Symmetry*, 12(5), 715.
- [18] A. Lu, B.B.P. Medeiros, K.R.B. Butler, P. Traynor (2026) “Read This Paper to Get \$50 Million: An Analysis of Mobile Messaging Scams Using Reddit Data,” *arXiv:2605.16656*.
- [19] T. Cao, C. Huang, Y. Li, H. Wang, A. He, N. Oo, B. Hooi (2025) “PhishAgent: A Robust Multimodal Agent for Phishing Webpage Detection,” *Proc. AAAI Conference on Artificial Intelligence*, 39(27), 27869–27877.